Министерство науки и высшего образования Российской Федерации

Самарский национальный исследовательский университет
имени академика С.П. Королева

Свёрточные нейронные сети (сети свертки)

Методические указания к лабораторной работе № 2
по курсу «НЕЙРОННЫЕ СЕТИ И ГЛУБОКОЕ ОБУЧЕНИЕ»

САМАРА
2026

Составители: д.ф.-м.н., профессор В.В.Мясников
к.т.н. А.Ю.Баврина

УДК 681.3

Свёрточные нейронные сети (сети свёртки)

Методические указания к лабораторной работе № 2
Самарский национальный исследовательский университет
имени академика С.П. Королева
Составители: В.В. Мясников, А.Ю.Баврина
Самара, 2026. 16 с.

В лабораторной работе № 1 по курсу «Свёрточные нейронные сети (сети свертки)» изучаются принципы работы и основные функции построения, обучения, оптимизации и оценки качества работы свёрточных нейронных сетей.

Методические указания предназначены для студентов, обучающихся по специализациям 10.05.03 - "Информационная безопасность автоматизированных систем" и 01.03.02 - "Прикладная математика и информатика".

Печатается по решению редакционно-издательского совета
Самарского национального исследовательского университета
имени академика С.П. Королева

Рецензент: д.ф.-м.н., профессор ФИО

Цель работы: изучить принципы работы и основные функции построения, обучения, оптимизации и оценки качества работы свёрточных нейронных сетей (CNN – Convolutional Neural Network).

СВЁРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ

1 Основные обозначения

Тензор — вводится как обобщение понятия скаляра, вектора и матрицы. Упрощенно может рассматриваться как многомерный массив чисел. В сверточных нейронных сетях (СНС) мы в основном будем иметь дело с 3х мерными тензорами, при этом:

- тензор ранга 0 будет соответствовать скаляру y∈R,

- тензор ранга 1 будет соответствовать вещественному вектору $y \in \mathbf{R}^K$,

- тензор ранга 2 будет соответствовать вещественной матрице Y∈ $\mathbf{R}^{N_1 \times N_2}$, где величины и выступают в качестве, соответственно, высоты и ширины матрицы или изображения;

- тензор ранга 3 будет соответствовать вещественному 3D массиву $\mathbf{y} \in \mathbf{R}^{N_1 \times N_2 \times K}$.

Основной операцией в сверточных нейронных сетях является операция *свертки*. Как мы помним, в классической свертке отсчеты ядра свертки перемножаются на отсчеты входной последовательности «в обратном порядке» (для обеспечения коммутативности операции). В СНС, в противоположность классическому определению, используют то же название «свертки», но применительно к выражению для *перекрестной корреляции*, записываемому в виде:

$$s(n) = \sum_{m=0}^{M-1} w(m)x(n+m), n = 0, \dots$$

Следуя этой сложившейся практике, мы также будем называть это выражение сверткой и также обозначать соответствующим значком «*».

Для трехмерного случая свертка входного тензора размера $N_1 \times N_2 \times K$ с ядром размера $M_1 \times M_2 \times K$ в простейшем случае запишется в виде:

$$S_{n_1 n_2} = \sum_{m_1=0}^{M_1-1} \sum_{m_2=0}^{M_2-1} \sum_{k=0}^{K-1} x_{n_1+m_1,\, n_2+m_2,\ k}\, w_{m_1,m_2,k}\,, n_1 = 0, \dots;\ , n_2 = 0, \dots \quad (5.1)$$

Для лучшей интерпретации этого выражения просто приведем пример расчета выходного тензора, где входной тензор имеет размеры $3 \times 3 \times 2$, а ядро $2 \times 2 \times 2$.

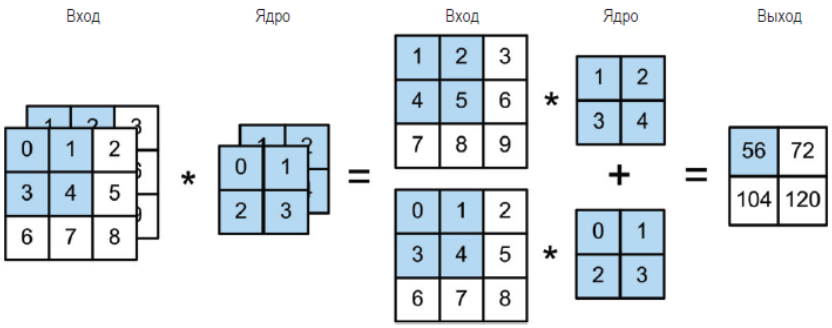

Рисунок 1.1 Корректная свертка (valid convolution)

Пространственная размерность выходного тензора составляет $(N_1 - M_1 + 1) \times (N_2 - M_2 + 1) \times 1$. Обратите внимание, что суммирование по третьему индексу в приведенном выражении происходит не в режиме свертки (нет суммирования индексов). То есть размер (глубина) тензора ядра свертки и тензора входного сигнала по этой координате полностью совпадает. Полученный тензор $S_{n_1 n_2}$, фактически двумерный (по пространству) интерпретируется в СНС как *поле (карта) признак*а (англ.: feature map).

Далее, представленный пример вычисления выходного тензора соответствует так называемой *корректной* (valid) свертки, когда ядро занимает все возможные позиции, полностью «помещаясь» во входном тензоре (то есть для каждого отсчета ядра есть соответствующее значение отсчета тензора. В этом случае, как очевидно, пространственный размер выходного тензора тем меньше, чем больше пространственный размер ядра. Однако в ряде задач требуется сохранение пространственного размера выходного тензора. Это может быть достигнуто путем дополнения входного тензора значениями за пространственными границами входного тензора. Дополнение можно проводить как нулями (чаще всего), так и ближайшими значениями. Процесс дополнения в СНС называется padding, и если пространственные размеры входного и выходного тензоров совпадают, то такую свертку называют *конгруэнтной* (в пакетах — флаг same). В случае использования дополнения нулями по P_1, P_2 отсчетов по каждой координате тензора, пространственный размер выходного тензора оказывается следующим:

$$(N_1 + P_1 - M_1 + 1) \times (N_2 + P_2 - M_2 + 1)$$

Сверточная нейронная сеть – преобразование, в котором последовательно (на каждом *слое*) применяются рассмотренные операции сверти. Выражение для r-ого *сверточного нейрона* l*-ого стоя типовой СНС имеет вид*:

$$y^l_{n_1,n_2,r} = f^l_r(s^{l,}_{n_1,n_2,r}),$$

$$s^l_{n_1,n_2,r} = \sum_{m_1=0}^{M^l_{r,1}-1}\sum_{m_2=0}^{M^l_{r,2}-1}\sum_{k=0}^{K^{l-1}-1} x^l_{S^l_1\cdot n_1+m_1,S^l_2\cdot n_2+m_2,k} w^{l,r}_{m_1,m_2,k} + b^l_r,\ n_1 = 0,\dots; n_2 = 0,\dots \quad (5.2)$$

Здесь b^l_r – *смещение* (bias), корректирующее результат работы r-ого сверточного сумматора на l-ом слое, S^l_1, S^l_2 – шаги по каждой пространственной координате, f – функция активации (которая может быть в общем случае разной не только для каждого слоя, но и для каждого сверточного сумматора).

Сверточный слой СНС – это набор сверточных нейронов для конкретного номера слоя l.

Основные характеристики сверточного слоя:

- число обучаемых параметров: $M^l_{r,1} \times M^l_{r,2} \times K^{l-1} + 1, r = \overline{0, K^l - 1}$ – отсчеты K^l фильтров слоя,

- метапараметры: количество и размеры фильтров, шаги и параметры дополнения входного тензора: $M^l_{r,1}, M^l_{r,1}, K^l, S^l_1, S^l_2, P^l_1, P^l_2$.

Частный случай — поточечная свертка (1x1)

Ядро для поточечной свертки выбирается размером 1×1×K. В результате сумматор в выражении (5.2) вычисляет скалярные произведения вектора ядра и векторов входного тензора, расположенных в каждой пространственной координате тензора (n_1, n_2):

$$S^l_{n_1,n_2,r} = \sum_{k=0}^{K-1} x_{n_1,n_2,k} w^{lr}_{0,0,k} + b^l_r, n_1 = 0,\dots,n_2 = 0,\dots$$

Результатом является двумерный тензор (аналог изображения), пространственно соразмерный входному тензору.

Содержательно операция может быть интерпретирована следующим образом:

- как вариант однослойного перцептрона,

- как примитивный коррелятор, применяемый ко всем векторам-признакам входного тензора;

- как проекция исходного вектора в некоторое новое пространство.

Некоторые выводы о СНС

- сверточные слои позволяют радикально (на порядки) снизить число

настраиваемых/обучаемых параметров в НС при сохранении числа нейронных связей по сравнению с обычной/классической архитектурой ИНС;

- последовательное использование сверточных слоев (5.2) с корректной сверткой (без дополнения) приводит к последовательному уменьшению пространственного размера выходных тензоров. Как следствие, процесс последовательного конструирования таких слоев в какой-то момент объективно завершится (как скоро - зависит от пространственного размера входного тензора и размеров ядра);

- для увеличения числа сверточных слоев (при использовании корректных сверток) можно использовать дополнение тензоров нулями. Однако следует помнить, что пространственно «крайние» значения отсчетов тензора будут в значительной степени зависеть от нулевых отсчетов-дополнений, то есть нести не так много содержательной информации;

- пространственный размер ядра свертки определяет его *поле восприятия (англ.: receptive field)* соответствующего фильтра СНС. По мере продвижения от первичных слоев СНС к конечным накопленный размер поля восприятия для фильтра становится все б*о*льшим и б*о*льшим, даже если первоначальные фильтры имеют малый размер. Например, последовательная свертка ядрами размером 3x3 дает фильтр размера 5x5, далее 7x7 и т.д. Все это позволяет ассоциировать фильтры первичных слоев СНС с простыми геометрическими или яркостными примитивами, а фильтры поздних слоев — с некоторыми осмысленными фигурами. Поскольку по мере роста поля восприятия фильтра осмысленных фрагментов становится все больше, типовым приемом является увеличение числа фильтров по мере продвижения в глубь СНС;

- размеры ядер и их количество напрямую определяет число параметров СНС (и, как следствие, число операций). Поэтому, например, часто выгоднее использовать два последовательных ядра 3x3 ($2*(3*3*K+1)=18K+2$ параметров), чем одно ядро 5x5 ($1*(5*5*K+1)=25K+1$ параметров). Аналогично, снижение числа параметров/операций в СНС возможно за счет использования «разделимых ядер». При этом факторизация ядра может быть проведена по-разному (по глубине или пространству, что дает разные итоговые решения).

2 Слой пулинга (объединения) и субдискретизация

Одним из типовых слоев СНС является слой *пулинга* (англ.: pooling). Функция пулига для конкретной пространственной координаты тензора определяется как некая агрегирующая функция по отсчетам входного тензора в окрестности этой пространственной координаты. Наиболее часто употребляемыми являются следующие два варианта пулинга (обратите внимание, что операция выполняется независимо для каждой карты признаков):

- max-пулинг, который оставляет локальное максимальное значение входного тензора:

$$y^l_{n_1,n_2,k} = \max_{(m_1,m_2)\in D}(x^l_{n_1+m_1,n_2+m_2,k}),$$

здесь D – некоторая область, которая определяет геометрию окрестности операции пулинга.

Иногда еще выделяют операцию глобального max-пулинга (Global MaxPooling) когда целая карта признаков превращается в одно значение:

$$y^l_{0,0,k} = \max_{(n_1,n_2)}(x^l_{n_1,n_2,k});$$

- average-пулинг, который оставляет локальное среднее значение входного тензора

$$y^l_{n_1,n_2,k} = \frac{1}{|D|}\sum_{(m_1,m_2)\in D} x^l_{n_1+m_1,n_2+m_2,k}.$$

Операция *объединения* используется совместно с операций *субдискретизации* (downsampling, subsampling) — прореживанием выходного тензора по пространственным координатам с некоторым шагом (stride). Типовым решением является, например, max-пулинг 2x2 с субдискретизацией в два раза по каждой координате. Пространственный размер выходного тензора в этом случае по каждой координате становится в два раза меньше.

<u>Основные характеристики слоя пулинга:</u>

- обучаемые параметры: отсутствуют;

- метапараметры: шаги S^l_1, S^l_2, тип пулинга.

3 Слои прямого распространения (Feed Forward Layer) или полносвязные (Full Connected) слои в СНС

Полносвязные слои (англ.: Dense) — слои, используемые в классических слоистых сетях или сетях прямого распространения (не стоит путать полносвязные сети и полносвязные слои — разные понятия). Использование полносвязных слоев в СНС производится обычно на последних слоях архитектуры СНС, когда пространственная информация в тензоре почти отсутствует (пространственный размер итогового тензора мал по сравнению с размером входного тензора), а основная размерность «перешла» в третью, признаковую, координату. Тогда с использованием FFL можно сформировать окончательное решение, например, решение о классе изображенного объекта.

Для преобразования результата(ов) сверточного слоя (то есть набора трехмерного тензора) в обычный слой FFL в программных пакетах используется функция «Flatten», которую содержательно можно перевести как «развертка» (но переводят как «разглаживание»). Трехмерный тензор $N_1 \times N_2 \times K$ разворачивается в одномерный (вектор) размера $N_1 \cdot N_2 \cdot K$.

Полносвязные слои можно представить в виде сверточных, в этом случае говорят о *полностью сверточной сети*.

Основные проблемы, решаемые при построении СНС

Можно указать следующие причины использования специализированных сверток и приемов:

- уменьшение количество параметров,
- уменьшение объемов потребляемой памяти,
- уменьшение объемов вычислений (количества операций) при применении ГНС (глубоких нейронных сетей),
- увеличение поля восприятия фильтров,
- улучшение (ускорение + стабилизация) сходимости/обучения,
- улучшение качества работы ГНС.

Некоторые приемы в СНС

Прием «бутылочное горлышко» (bottleneck)

Термином «бутылочное горлышко» обычно называют такие способы организации вычислений в ИНС, при которых входной тензор «упаковывается»/сжимается до тензора или некоторой структуры меньшего размера (по числу параметров), после чего на выходе возвращается к первоначальному или большему размеру тензора.

Пример «бутылочного горлышка» легко проиллюстрировать на классической ИНС, как показано на рисунке ниже.

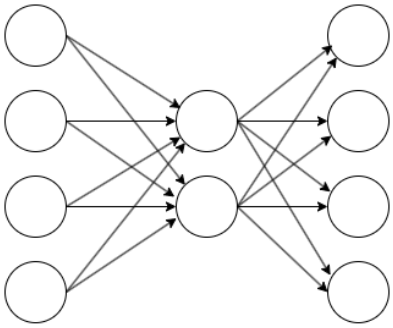

Передача информации на последующие слои (слой)

Данный прием обычно используется в одном из двух основных вариантах:

1) тензор, получаемый в результате обработки и обозначаемый $F_W(x)$, складывается с входным тензором x. В виде формулы это можно записать следующим образом:

$$y = F_W(x) + x.$$

2) тензор, получаемый в результате обработки, конкатенируется (объединяется) с входным тензором (по глубине) и, возможно, с предшествующими входными тензорами в группе. Поскольку такое объединение приводит к значительному росту глубины тензора, после ряда таких конкатенаций обычно идет слой снижения размерности (по глубине) с использованием свертки 1x1.

Первый подход был предложен в сети ResNet, второй — в DenseNet.

<u>Пакетная нормализация, нормализация слоя, Dropout</u>

Нормализация по батчу (BN) и нормализация слоя (LN) для СНС решает те же задачи, что и в случае обычных ИНС и механизмов нормализации.

Механизм Dropout обычно используют после преобразования набора карт

признаков в одномерный вектор (методом Flatten). Применение Dropout после слоя свертки возможно, но нецелесообразно (делает карты признаков зашумленными). Для применения после свертки в пакетах есть версия SpatialDropout2D, которая «отключает» отдельные карты признаков, уменьшая при этом корреляционные зависимости между картами.

Типовое построение СНС

Типовой вид СНС представлен на рисунке ниже. Вначале обычно идет последовательность пар СверточныйСлой+СлойПулинга, затем получаемый тензор разворачивается в вектор значений и далее идет классическая сеть прямого распространения. Итоговый слой определяется задачей, для задачи классификации в выходном слое обычно используется функция активации softmax.

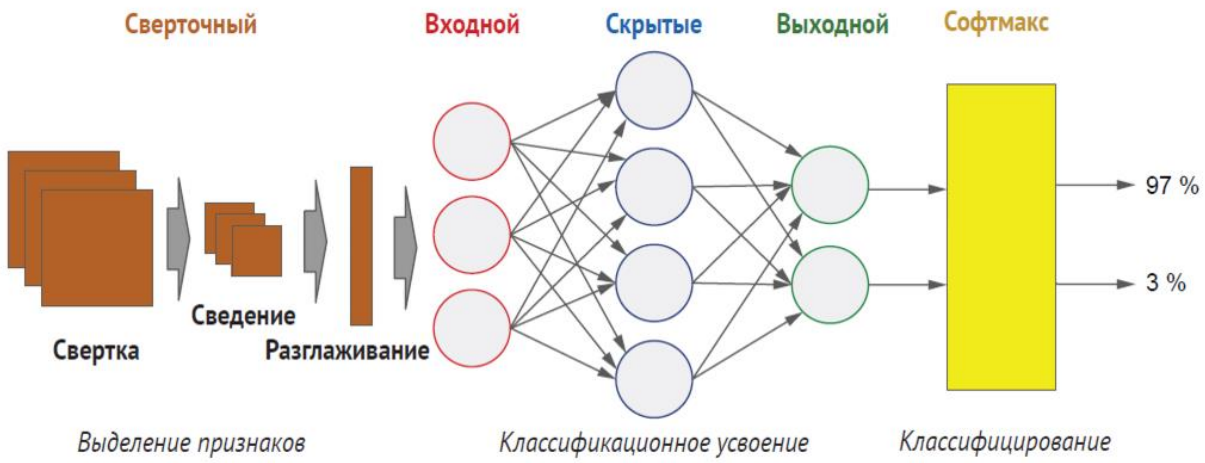

Самую типовую СНС можно описать следующим образом:

INPUT -> [[CONV -> RELU]*N -> POOL?]*M -> [FC -> RELU]*K -> FC->SOFTMAX

здесь:

INPUT — входной тензор,

CONV — сверточный слой (обычный или специализированный),

RELU — активационная функция,

*N, *M, *K — число повторов соответствующего блока,

POOL? — (возможно присутствующий) макспулинг,

FC — полносвязный слой.

<u>Основные данные, характеризующие CNN</u>

- архитектура CNN,

- **число параметров** ~размер сети (в сверточных/FFL слоях),

- число операций (=время выполнения/обучения ~ **число нейронных связей**)

- значение критерия качества.

2. ЛИТЕРАТУРА

1. Хайкин С. «Нейронные сети. Полный курс», 2006

2. Гудфеллоу Я., Бенджио И., А.Курвиль Глубокое обучение, ДМК Пресс, 2017

3. Николенко С., Кадурин А., Архангельская Е. Глубокое обучение. — СПб.: Питер, 2018. — 480 с.: ил.

4. Бишоп К. М.,Бишоп Х. Глубокое обучение: принципы и концепции, ДМК Пресс, 2025.

5. Принс Саймон Машинное обучение. От основ до продвинутых моделей (серия - Библиотека MIT), 2025.

3. ПОРЯДОК ВЫПОЛНЕНИЯ ЛАБОРАТОРНОЙ РАБОТЫ

3.1. Исходные данные

Набор данных cifar10.

3.2. Общий план выполнения работы

1. Загрузить данные для обучения и тестирования cifar10.

В этой базе представлены цветные изображения размером 32x32 десяти классов: ['airplane','automobile','bird','cat','deer','dog','frog','horse','ship','truck'].

При первой загрузке, скорее всего, данные будут загружены с сайта, при последующих — с диска.

Вывести на экран по 2-3 изображения каждого класса.

2. Построить следующую модель:

- входной слой, соответствующий размеру входных изображений
- последовательно три сверточных слоя, чередующиеся со слоями MaxPooling,
- слой развертки (Flatten)
- полносвязный слой (активация relu)
- выходной слой (10 классов, активация softmax).

Количество фильтров в сверточных слоях можно брать 32, 64, 128.

Между слоем развертки и полносвязным разместить Dropout.

Обучить модель на обучающей выборке (заложив традиционный процент на валидацию). Вывести графики зависимости точности и потери на обучающей и валидационной выборках от номера эпохи.

Уметь выписать формулу для количества настраиваемых весов для слоя свертки.

При обучении предусмотреть сохранение лучших весов с использованием callbacks.

Сохранить модель для использования в дальнейшем. При загрузке обученной модели не забывать загружать в нее лучшие сохраненные веса.

Произвести классификацию тестовой выборки, вывести несколько изображений, которые были проклассифицированы неверно.

Записать процент правильной классификации для каждого класса.

3. Цель данного пункта заключается в освоении механизма transfer learning.

Обучив модель на 8 классах, мы замораживаем обучение сверточных слоев и дообучаем модель на распознавание 10 классов.

Сделать это можно таким образом.

- Удалить из обучающей выборки 2 класса (произвольные, но **разные для разных студентов**), переформировав соответствующим образом обучающую выборку и метки классов.
- Обучить модель с архитектурой из предыдущего пункта на 8-ми классах.
- Удалить из этой модели последние два полносвязных слоя (выходной и «скрытый»), заморозить обучение остальных слоев.

Создать новую модель, первым слоем которой будет предыдущая замороженная модель, а потом идут новые обучаемые полносвязные слои (выходной слой должен быть на 10 классов).

Произвести компиляцию и обучение новой модели (на первоначальных полных тестовых данных).

Произвести классификацию на тестовом наборе, записать точность классификации для выброшенных 2-х классов и сравнить это значение со значением, полученным в пункте 2. Сделать выводы.

Примечание. В случае, если обучение на ваших ноутбуках занимает довольно много времени, можно сохранять логи по эпохам для демонстрации во время показа работы. Если не хватает памяти для обучения, можете уменьшить количество изображений в обучающей выборке (следите, чтобы это было равномерно по классам).

Используемые функции:

model.pop() - удаляет из модели последний добавленный слой

model.trainable=False - замораживает обучение всех слоев модели (можно и отдельно по нужным слоям)

tf.keras.layers.Conv2D(...) - добавление сверточного слоя

tf.keras.layers.MaxPooling2D(...) - добавление слоя макспулинга

3.3. Содержание отчета

4. КОНТРОЛЬНЫЕ ВОПРОСЫ

СОДЕРЖАНИЕ

Свёрточные нейронные сети (сети свёртки) 2
Свёрточные нейронные сети 3
1 Основные обозначения 3
Основные характеристики сверточного слоя: 5
Частный случай — поточечная свертка (1x1) 5
Некоторые выводы о СНС 5
2 Слой пулинга (объединения) и субдискретизация 7
3 Слои прямого распространения (Feed Forward Layer) или полносвязные (Full Connected) слои в СНС 8
Основные проблемы, решаемые при построении СНС 8
Некоторые приемы в СНС 9
Прием «бутылочное горлышко» (bottleneck) 9
Передача информации на последующие слои (слой) 9
Пакетная нормализация, нормализация слоя, Dropout 9
Типовое построение СНС 10
Основные данные, характеризующие CNN 10
2. Литература 11
3. Порядок Выполнения лабораторной работы 12
3.1. Исходные данные 12
3.2. Общий план выполнения работы 12
Используемые функции: 13
3.3. Содержание отчета 14
4. Контрольные вопросы 14
Содержание 15

Учебное издание

Сверточные нейронные сети (сети свертки)

Методические указания к лабораторной работе № 2

по курсу «Нейронные сети и глубокое обучение»

Составители: Мясников Владислав Валерьевич

Баврина Алина Юрьевна

Самарский национальный исследовательский университет

имени академика С.П. Королева

443086, Самара, Московское шоссе, 34

Отпечатано на кафедре «Геоинформатика и информационная безопасность»

Тираж 20 экз.