

Алгоритм обратного распространения

$$\begin{aligned}\tilde{h}(t) &= W_{hh}h(t-1) + W_{xh}x(t) + b_h, & h(t) &= f_h(\tilde{h}(t)), \\ \tilde{y}(t) &= W_{hy}h(t) + b_y, & y(t) &= f_y(\tilde{y}(t)).\end{aligned}\quad (1)$$


Для критерия:

$$L = \frac{1}{T} \sum_{t=0}^{T-1} l(y^{true}(t), y(t)).$$

в виде кросс-энтропии и активационной функции softmax на выходе, так что

$$l'(y^{true}(t), y(t))f'_y(\tilde{y}(t)) = \begin{cases} y_k(t) - 1, & p_k^{true} \neq 1; \\ y_k(t), & p_k^{true} = 1. \end{cases}\quad (2)$$

и активационной функции в виде гиперболического тангенса $f_h(\dots) = \tanh(\dots)$, так что $\tanh'(\dots) = 1 - \tanh^2(\dots)$.



Как видно из рисунка $h(t)$ влияет непосредственно на $h(t+1)$ и $y(t)$. Тогда, используя правило дифференцирования сложной функции (цепное правило), имеем:

$$\frac{\partial L}{\partial h(t)} = \frac{\partial L}{\partial y(t)} \frac{\partial y(t)}{\partial h(t)} + \frac{\partial L}{\partial h(t+1)} \frac{\partial h(t+1)}{\partial h(t)}$$

Из вида (1) получаем:

$$\frac{\partial y(t)}{\partial h(t)} = f'_y(\tilde{y}(t))W_{hy}, \quad \frac{\partial h(t+1)}{\partial h(t)} = f'_h(\tilde{h}(t))W_{hh}$$

Тогда обратное распространение производной имеет вид:

$$\frac{\partial L}{\partial h(t)} = \frac{\partial L}{\partial y(t)} f'_y(\tilde{y}(t))W_{hy} + \frac{\partial L}{\partial h(t+1)} f'_h(\tilde{h}(t))W_{hh}. \quad (3)$$

Имея производные $\frac{\partial L}{\partial h(t)}$, можно получить производные по остальным параметрам выражения (1): W_{hh} , W_{xh} и b_h . Поскольку каждая из этих величин влияет непосредственно на каждое значение $h(t)$, имеем (например, для b_h):

$$\frac{\partial L}{\partial b_h} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} \frac{\partial h(t)}{\partial b_h}$$

Поскольку $\frac{\partial L}{\partial h(t)}$ у нас вычисляется в (3), расписываем производную только второго сомножителя в каждом суммируемом терме:

$$\frac{\partial L}{\partial b_h} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} f'_h(\tilde{h}(t)) \frac{\partial \tilde{h}(t)}{\partial b_h} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} f'_h(\tilde{h}(t)) 1 = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} f'_h(\tilde{h}(t)).$$

Аналогично:

$$\frac{\partial L}{\partial W_{hx}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} \frac{\partial h(t)}{\partial W_{hx}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} f'_h(\tilde{h}(t)) \frac{\partial \tilde{h}(t)}{\partial W_{hx}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} f'_h(\tilde{h}(t)) x(t),$$

$$\frac{\partial L}{\partial W_{hh}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} \frac{\partial h(t)}{\partial W_{hh}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} f'_h(\tilde{h}(t)) \frac{\partial \tilde{h}(t)}{\partial W_{hh}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial h(t)} f'_h(\tilde{h}(t)) h(t-1).$$

Для параметров W_{hy} и b_y имеем, аналогично:

$$\frac{\partial L}{\partial W_{hy}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial \tilde{y}(t)} \frac{\partial \tilde{y}(t)}{\partial W_{hy}} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial \tilde{y}(t)} h(t),$$

$$\frac{\partial L}{\partial b_y} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial \tilde{y}(t)} \frac{\partial \tilde{y}(t)}{\partial b_y} = \sum_{t=0}^{T-1} \frac{\partial L}{\partial \tilde{y}(t)} 1 = \sum_{t=0}^{T-1} \frac{\partial L}{\partial \tilde{y}(t)},$$

При том, что

$$\frac{\partial L}{\partial \tilde{y}(t)} = l'(y^{true}(t), y(t)) f'_y(\tilde{y}(t)).$$

и определяется в выражении (2).